

SciGYM-SMALL における OPEN-WEIGHT モデルの事前登録評価: RIKYU の推論 API で提供される 8 モデルは論文の GPT-4.1-MINI に届くか

Anonymous authors

Paper under double-blind review

ABSTRACT

SciGym (Duan et al., 2025) は、反応をすべて取り除いた SBML モデルを LLM エージェントに渡し、摂動実験とコード実行を繰り返して反応機構を復元させるベンチマークである。論文の Table 1 は 3 社のフロンティアモデル 6 つを SciGym-small 137 件で各 1 回走らせた平均値を報告しているが、open-weight モデルは含まれていない。本研究は、公開コードの Controller と評価器をそのまま用い、理研の計算機 RIKYU の推論 API で提供される open-weight 8 モデル (deepseek-v4.1-flash, glm-5.2, glm-5.3, glm-5.3-flash, kimi-k2.6, kimi-k3, qwen3.6-35b, qwen3.8-27b) を同じプロトコルで評価する。実験前に、(1) GLM-5.3 系を除く 6 モデルの平均 Simulation Trajectory Error (STE) が論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らないこと、(2) glm-5.3 の平均 STE が glm-5.3-flash 以下であること、を反証線として登録する。Reaction Matching Score (RMS) と Network Topology Score (NTS) は同じ実行から表として報告する。実行は RIKYU (aarch64) 上で行い、論文設定からの逸脱 (libroadrunner 2.7.0、応答トークン上限、推論 API の提供形態) はすべて実験前に宣言する。

1 はじめに

LLM に科学的発見のサイクル全体（実験の設計、結果の解析、機構の提案）を行わせて測るベンチマークとして、SciGym (Duan et al., 2025) が提案された。BioModels 由来の SBML モデルから反応をすべて取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し、返ってきた時系列を Python で解析し、最終的な SBML を提出する。提出モデルは真のモデルと、軌道誤差 (STE) と反応の一致度 (RMS) で比較される。

論文の主結果である Table 1 は、3 社の pro / mini 計 6 モデルを SciGym-small の 137 件で評価した平均値である (Duan et al., 2025, s1.p2, s1.p10)。評価対象はすべて商用 API のモデルであり (Duan et al., 2025, s1.p1)、open-weight モデルがこの閉ループの課題でどこまで到達するかは示されていない。open-weight モデルは自前の計算機で動かせるため API 費用がかからず、版が固定されるので再現もしやすい。本研究では、理研の計算機 RIKYU の推論 API (OpenAI 互換) で提供される 8 モデルを、公開コード (h4duan, 2025) の Controller をそのまま使って同じプロトコルで評価する。

判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録へ凍結し、実験後は計測値だけを流し込む。比較対象は論文 Table 1 の値であり、本研究では商用モデルを再実行しない。

2 関連研究

SciGym (Duan et al., 2025) は、単一スキルを測る既存のベンチマークと異なり、エージェントが自ら摂動実験を設計してその結果を受け取る閉ループを評価する。評価指標は 3 つで、種間の相互作用の F1 (NTS)、反応物と生成物の集合が一致した反応の適合率・再現率・F1 (RMS。modifier まで要求する厳格版もある) (Duan et al., 2025, s1.p8)、および全種の時系列の対称平均絶対パーセント誤差 (STE) (Duan et al., 2025, s1.p9) である。

論文は pro モデルが mini モデルを一貫して上回り (Duan et al., 2025, s1.p6)、Gemini-Pro が最良であった (Duan et al., 2025, s1.p7) と報告している。本研究の仮説 2 は、この pro と mini の関係が open-weight の同一ファミリー (glm-5.3 と glm-5.3-flash) でも成り立つかを問う。

3 仮説と予測

以下は記録 (record.json) から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. RIKYU の推論 API (OpenAI 互換) で提供される open-weight モデル 6 種 (deepseek-v4.1-flash, glm-5.2, kimi-k2.6, kimi-k3, qwen3.6-35b, qwen3.8-27b) は、SciGym 公開コードの Controller をそのまま用いて SciGym-small 137 件を最大 20 反復で解かせたとき、いずれも平均 Simulation Trajectory Error (STE) が論文 Table 1 の GPT-4.1-mini (0.6007) の水準に届く (0.05 より大きくは上回らない)。(Duan et al., 2025, s1.p1, s1.p5, s1.p10)

- Claim 1** deepseek-v4.1-flash で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* DeepSeek 系で唯一提供されている flash モデルが GPT-4.1-mini の水準に届けば、h1 の deepseek-v4.1-flash の部分を担う。 *Criterion:* `deepseek-v4.1-flash.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (論文 Table 1 で 2025 年前半の mini モデルは 0.42~0.63, pro モデルは 0.32~0.46。2026 年の open-weight thinking モデルは論文の pro と mini の間に入ると見込み、GPT-4.1-mini との差は -0.30~0 と予測する)。 *Observed:* pending. *Verdict:* pending.
- Claim 2** glm-5.2 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* GLM 系の前世代モデルが GPT-4.1-mini の水準に届けば、h1 の glm-5.2 の部分を担う。 *Criterion:* `glm-5.2.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ。前世代のため h1 の中では差が小さい側に出ると見込む)。 *Observed:* pending. *Verdict:* pending.
- Claim 3** kimi-k2.6 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Kimi 系の前世代モデルが GPT-4.1-mini の水準に届けば、h1 の kimi-k2.6 の部分を担う。 *Criterion:* `kimi-k2.6.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ)。 *Observed:* pending. *Verdict:* pending.
- Claim 4** kimi-k3 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Kimi 系の現行モデルが GPT-4.1-mini の水準に届けば、h1 の kimi-k3 の部分を担う。 *Criterion:* `kimi-k3.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ。現行世代の大型モデルのため差が大きい側に出ると見込む)。 *Observed:* pending. *Verdict:* pending.
- Claim 5** qwen3.6-35b で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Qwen 系の 35B モデルが GPT-4.1-mini の水準に届けば、h1 の qwen3.6-35b の部分を担う。 *Criterion:* `qwen3.6-35b.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ)。 *Observed:* pending. *Verdict:* pending.
- Claim 6** qwen3.8-27b で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Qwen 系の 27B モデルが GPT-4.1-mini の水準に届けば、h1 の qwen3.8-27b の部分を担う。最も小さいモデルであり h1 の下限を決める。 *Criterion:* `qwen3.8-27b.trajectory_smape`

– $0.6007 \leq 0.05$. *Prediction*: $[-0.3, 0]$ (c1 と同じ。最小のモデルのため差が小さい側に出ると見込む). *Observed*: pending. *Verdict*: pending.

Assumed, so that the claims together imply Hypothesis 1:

- temperature 1.0 での 1 回実行の平均 STE (137 件平均) の実行間変動が 0.05 より十分小さいこと。先行する Table 1 再現では件ごとの STE の標準偏差はおおよそ 0.27、137 件平均の標準誤差はおおよそ 0.02 であった (c1~c6)
- RIKYU の推論 API が提供する各モデルが、公開重みと同等の能力を持つこと。量子化や serving の設定は公開されていない (c1~c6)
- thinking を出力するモデルでも max_tokens 32768 の範囲で本文が返り、本文が空のときの呼び直し (最大 3 回) で十分であること (c1~c6)
- aarch64 向けの libroadrunner 2.7.0 と antimony 2.14.0 が、論文環境の libroadrunner 2.8.0 と同じ軌道と評価値を与えること (c1~c6)
- 平均 STE が GPT-4.1-mini の水準に届くかどうかを代表すること。RMS (modifier あり / なし) と NTS は同じ実行から表として報告するが、判定基準には用いない (c1~c6)
- 論文の GPT-4.1-mini の値 (0.6007) を比較対象とすること。GPT-4.1-mini を同じ Controller で再実行した先行研究でも 0.60 前後であり、論文値をそのまま使う (c1~c6)

Hypothesis 2. 論文が報告する「各ファミリーで pro 版が mini 版を一貫して上回る」という構図は、open-weight の GLM-5.3 系でも成り立ち、glm-5.3 は glm-5.3-flash より SciGym-small の平均 STE が低い。 (Duan et al., 2025, s1.p6, s1.p10)

Claim 7 glm-5.3 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、同条件の glm-5.3-flash の平均 STE 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p6, s1.p10), (h4duan, 2025, s2.p1) *Rationale*: 同一ファミリー・同世代の大小 2 モデルを同じ Controller で比べる直接の検証であり、h2 の全体を担う。 *Criterion*: $\text{glm-5.3.trajectory_smape} - \text{glm-5.3-flash.trajectory_smape} \leq 0$. *Prediction*: $[-0.15, -0.02]$ (論文 Table 1 の pro と mini の STE 差は Gemini で -0.097、GPT で -0.140。open-weight でも同程度か、やや小さい差を予測する). *Observed*: pending. *Verdict*: pending.

Assumed, so that the claims together imply Hypothesis 2:

- glm-5.3-flash が glm-5.3 と同世代の小型版であること。両者の構成は公開されておらず、名前から仮定する (c7)
- 平均 STE の差 1 本で「上回る」を代表すること。論文は STE と RMS の両方で pro > mini としているが、RMS は表で報告するのみで判定には用いない (c7)
- temperature 1.0 での 1 回実行どうしの比較で、差 0 を境とする判定が実行間変動 (標準誤差おおよそ 0.02) に対して十分頑健であること。差が 0.02 未満のときは結論が揺らぎうる (c7)

判定基準と予測区間の根拠. 仮説 1 の各主張の反証線は「(当該モデルの平均 STE) – (論文の GPT-4.1-mini の STE) ≤ 0.05 」である。GPT-4.1-mini は論文 Table 1 の 6 モデルのうち Claude-3.5-Haiku に次いで STE が大きく、「フロンティアモデルの mini 版に届く」ことの最低線として選んだ。0.05 は、論文 Table 1 で隣り合うモデルの最小差 (Gemini-2.5-Pro の 0.3212 と Claude-3.7-Sonnet の 0.3615 の差 0.04) とほぼ同じで、1 件の STE の標準偏差を 0.27 程度と見積もったときの 137 件平均の標準誤差 (約 0.02) の 2 倍強にあたる。予測区間は $[-0.30, 0]$ とし、2026 年の open-weight thinking モデルは論文の pro と mini の間に入ると見込む。

仮説 2 の反証線は「glm-5.3 の平均 STE – glm-5.3-flash の平均 STE ≤ 0 」である。論文 Table 1 の pro と mini の STE 差は Gemini で -0.097、GPT で -0.140 であり、予測区間は $[-0.15, -0.02]$ とする。2 つの 1 回実行の差の標準誤差は約 0.03 なので、差が 0.02 未満のときは結論が揺らぎうることを前提として記録する。

RMS (modifier あり / なし) と NTS も同じ実行から表として報告するが、1 つの主張に置ける判定基準は 1 つであるため、判定には用いない。

4 方法

タスク. 各インスタンスは真の SBML (truth.xml)、反応を取り除いた不完全な SBML (partial.xml)、シミュレーション条件 (truth.sedml) からなる。エージェントは不完全な SBML を受け取り、各ターンで実験 (初期濃度の変更を指定し、真のモデルの時系列を得る)、コード実行 (numpy / pandas / scipy / libsbml と、仮説モデルを走らせる simulate 関数が使える)、提出のいずれかを markdown 形式で返す。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p3)。提出した SBML が無効な場合は追加のデバッグ反復が許され、それでも無効なら不完全 SBML のまま採点される (Duan et al., 2025, s1.p4)。

実行系. ループ、プロンプト、実験の実行はすべて公開コード (h4duan, 2025) の Controller をそのまま用いる。本研究が書くのは、(1) OpenAI 互換 API でモデルを呼ぶ LLM 実装 (公式の GPT 実装と同じく、システムプロンプトと全履歴を毎回送る)、(2) インスタンスごとに 1 プロセスで Controller を起動し、137 件を並列に走らせる駆動部、(3) 各インスタンスの提出モデルと公式データを評価層の入力ファイルに書き出す部分だけである。公式コードでは履歴がクラス属性として定義されており 1 プロセスで複数件を走らせると履歴が持ち越されるが、1 件 1 プロセスとすることでこの問題を避ける。

指標. 採点は評価層 airas-eval のベンチマークパック scigym_small が行う。パックは公式リリースの 137 件 (truth / partial / sedml) を sha256 で固定し、公開コードの Evaluator (コミット 88a7b93) で提出モデルを採点して、STE (trajectory_smap)、RMS の適合率・再現率・F1 (modifier なし reaction_*, あり reaction_*_with_modifiers)、NTS の F1 (topology_f1) を 137 件の単純平均で返す。提出 SBML が無い、または無効な件は、公式評価どおり不完全 SBML の採点値で平均に含める。

5 実験設計

モデル. RIKYU の推論 API が提供する 8 モデルをすべて用いる: deepseek-v4.1-flash、glm-5.2、glm-5.3、glm-5.3-flash、kimi-k2.6、kimi-k3、qwen3.6-35b、qwen3.8-27b。いずれも思考 (thinking) を出力するモデルである。各モデルの量子化や serving の設定は公開されておらず、公開重みと同等の能力を持つことを仮説の前提として記録する。

データ. SciGym-small の 137 件 (Duan et al., 2025, s1.p2) (Hugging Face h4duan/scigym-sbml の small split と同一内容の RIKYU 上のコピー) を用いる。評価層は各件の内容を公式リリースの sha256 と照合する。

設定. max_iterations は論文どおり 20 (Duan et al., 2025, s1.p3) (公開 config の既定値は 5 (h4duan, 2025, s2.p2))、eval_debug_rounds は論文本文の 3 (Duan et al., 2025, s1.p4) (公開 config の既定値は 5 (h4duan, 2025, s2.p3))、temperature は公開 config の 1.0 (h4duan, 2025, s2.p1)、摂動は初期濃度の変更のみとする。応答のトークン上限は 32768 とする。公式の GPT 実装の既定値 8192 では、思考トークンを出すモデルが本文を返せずに失敗しうるためである。本文が空で返った呼び出しは最大 3 回まで呼び直す。各モデル、各インスタンスを 1 回ずつ実行する。

計算資源と環境. 実行は Seyval を通じて RIKYU (Slurm、GB200 ノード、aarch64) で行い、LLM は同じ RIKYU の推論 API を呼ぶ。GPU は使わないが、資源の単位が GPU であるため 1 GPU を要求する。環境は Dockerfile と uv.lock で固定する。aarch64 向けの wheel が無いため、libroadrunner は公式の 2.8.0 ではなく 2.7.0、antimony は 2.14.0 を用い、rrplugins と phrasedml は除外する。この差でシミュレーション結果がわずかに変わる可能性があり、仮説の前提として記録する。

段階. sanity は 1 件 (BIOMD0000000027) を 2 反復で走らせて配管を確かめる。pilot は sorted した 137 件から 14 件おきに選んだ 10 件を 20 反復で走らせ、1 件あたりの所要時間

と推論 API の処理能力を測って全件実行の並列度を決める。主張の判定は full (137 件) の結果だけで行い、sanity と pilot の結果は記録に取り込まない。

run と主張の対応. deepseek-v4.1-flash → Claim 1、glm-5.2 → Claim 2、kimi-k2.6 → Claim 3、kimi-k3 → Claim 4、qwen3.6-35b → Claim 5、qwen3.8-27b → Claim 6、glm-5.3 と glm-5.3-flash → Claim 7。

6 結果

実験は未実施である。実行後にこの節へ、各 run の平均 STE、GPT-4.1-mini との差、RMS、NTS を table1 として、また各主張の判定基準に対する計測値を記入する。

7 考察

実験は未実施である。

8 結論

実験は未実施である。

データの利用可能性

記録は record.json にある。実験コード、環境の固定 (Dockerfile と uv.lock)、各 run の結果と provenance は同じリポジトリに含まれる。

REFERENCES

Haonan Duan, Stephen Zhewen Lu, Caitlin Fiona Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *arXiv preprint arXiv:2507.02083 (NeurIPS 2025 Datasets and Benchmarks Track)*, 2025. URL <https://arxiv.org/pdf/2507.02083>.

h4duan. h4duan/scigym, 2025. URL <https://github.com/h4duan/SciGym>. commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.