

SciGYM-SMALL における OPEN-WEIGHT モデルの事前登録評価: RIKYU の推論 API で提供される 8 モデルは論文の GPT-4.1-MINI に届くか

Anonymous authors

Paper under double-blind review

ABSTRACT

SciGym (Duan et al., 2025) は、反応をすべて取り除いた SBML モデルを LLM エージェントに渡し、摂動実験とコード実行を繰り返して反応機構を復元させるベンチマークである。論文の Table 1 は 3 社のフロンティアモデル 6 つを SciGym-small 137 件で各 1 回走らせた平均値を報告しているが、open-weight モデルは含まれていない。本研究は、公開コードの Controller と評価器をそのまま使い、理研の計算機 RIKYU の推論 API で提供される open-weight 8 モデル (deepseek-v4.1-flash、glm-5.2、glm-5.3、glm-5.3-flash、kimi-k2.6、kimi-k3、qwen3.6-35b、qwen3.8-27b) を同じプロトコルで評価する。実験前に、(1) GLM-5.3 系を除く 6 モデルの平均 Simulation Trajectory Error (STE) が論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らないこと、(2) glm-5.3 の平均 STE が glm-5.3-flash 以下であること、を反証線として登録する。Reaction Matching Score (RMS) と Network Topology Score (NTS) は同じ実行から表として報告する。実行は RIKYU (aarch64) 上で行い、論文設定からの逸脱 (libroadrunner 2.7.0、応答トークン上限、推論 API の提供形態) はすべて実験前に宣言する。実験の結果、完走した 5 モデル (deepseek-v4.1-flash、kimi-k2.6、kimi-k3、qwen3.6-35b、qwen3.8-27b) はすべて GPT-4.1-mini の水準に届き、うち 4 モデルは論文 Table 1 の最良値 (Gemini-2.5-Pro、STE 0.3212) も上回った。GLM 系 3 モデルは推論 API の生成速度の問題で期限内に終わらず打ち切ったため、仮説 2 は判定できなかった。

1 はじめに

LLM に科学的発見のサイクル全体 (実験の設計、結果の解析、機構の提案) を行わせて測るベンチマークとして、SciGym (Duan et al., 2025) が提案された。BioModels 由来の SBML モデルから反応をすべて取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し、返ってきた時系列を Python で解析し、最終的な SBML を提出する。提出モデルは真のモデルと、軌道誤差 (STE) と反応の一致度 (RMS) で比較される。

論文の主結果である Table 1 は、3 社の pro / mini 計 6 モデルを SciGym-small の 137 件で評価した平均値である (Duan et al., 2025, s1.p2, s1.p10)。評価対象はすべて商用 API のモデルであり (Duan et al., 2025, s1.p1)、open-weight モデルがこの閉ループの課題でどこまで到達するかは示されていない。open-weight モデルは自前の計算機で動かせるため API 費用がかからず、版が固定されるので再現もしやすい。本研究では、理研の計算機 RIKYU の推論 API (OpenAI 互換) で提供される 8 モデルを、公開コード (h4duan, 2025) の Controller をそのまま使って同じプロトコルで評価する。

判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録へ凍結し、実験後は計測値だけを流し込む。比較対象は論文 Table 1 の値であり、本研究では商用モデルを再実行しない。

2 関連研究

SciGym (Duan et al., 2025) は、単一スキルを測る既存のベンチマークと異なり、エージェントが自ら摂動実験を設計してその結果を受け取る閉ループを評価する。評価指標は3つで、種間の相互作用の F1 (NTS)、反応物と生成物の集合が一致した反応の適合率・再現率・F1 (RMS, modifier まで要求する厳格版もある) (Duan et al., 2025, s1.p8)、および全種の時系列の対称平均絶対パーセント誤差 (STE) (Duan et al., 2025, s1.p9) である。

論文は pro モデルが mini モデルを一貫して上回り (Duan et al., 2025, s1.p6)、Gemini-Pro が最良であった (Duan et al., 2025, s1.p7) と報告している。本研究の仮説 2 は、この pro と mini の関係が open-weight の同一ファミリー (glm-5.3 と glm-5.3-flash) でも成り立つかを問う。

3 仮説と予測

以下は記録 (record.json) から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. RIKYU の推論 API (OpenAI 互換) で提供される open-weight モデル 6 種 (deepseek-v4.1-flash, glm-5.2, kimi-k2.6, kimi-k3, qwen3.6-35b, qwen3.8-27b) は、SciGym 公開コードの Controller をそのまま用いて SciGym-small 137 件を最大 20 反復で解かせたとき、いずれも平均 Simulation Trajectory Error (STE) が論文 Table 1 の GPT-4.1-mini (0.6007) の水準に届く (0.05 より大きくは上回らない)。(Duan et al., 2025, s1.p1, s1.p5, s1.p10)

- Claim 1** deepseek-v4.1-flash で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* DeepSeek 系で唯一提供されている flash モデルが GPT-4.1-mini の水準に届けば、h1 の deepseek-v4.1-flash の部分を担う。 *Criterion:* `deepseek-v4.1-flash.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (論文 Table 1 で 2025 年前半の mini モデルは 0.42~0.63, pro モデルは 0.32~0.46。2026 年の open-weight thinking モデルは論文の pro と mini の間に入ると見込み、GPT-4.1-mini との差は -0.30~0 と予測する)。 *Observed:* -0.36024. *Verdict:* supported.
- Claim 2** glm-5.2 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* GLM 系の前世代モデルが GPT-4.1-mini の水準に届けば、h1 の glm-5.2 の部分を担う。 *Criterion:* `glm-5.2.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ。前世代のため h1 の中では差が小さい側に出ると見込む)。 *Observed:* pending. *Verdict:* pending.
- Claim 3** kimi-k2.6 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Kimi 系の前世代モデルが GPT-4.1-mini の水準に届けば、h1 の kimi-k2.6 の部分を担う。 *Criterion:* `kimi-k2.6.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ)。 *Observed:* -0.39065. *Verdict:* supported.
- Claim 4** kimi-k3 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Kimi 系の現行モデルが GPT-4.1-mini の水準に届けば、h1 の kimi-k3 の部分を担う。 *Criterion:* `kimi-k3.trajectory_smape - 0.6007 ≤ 0.05`. *Prediction:* $[-0.3, 0]$ (c1 と同じ。現行世代の大型モデルのため差が大きい側に出ると見込む)。 *Observed:* -0.375628. *Verdict:* supported.
- Claim 5** qwen3.6-35b で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Qwen 系の 35B モデルが GPT-4.1-mini の水準に届けば、h1 の qwen3.6-35b の部分を担う。

Criterion: `qwen3.6-35b.trajectory_smape` $- 0.6007 \leq 0.05$. *Prediction:* $[-0.3, 0]$ (c1 と同じ). *Observed:* -0.143611. *Verdict:* supported.

Claim 6 qwen3.8-27b で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文の GPT-4.1-mini の 0.6007 を 0.05 より大きくは上回らない。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* Qwen 系の 27B モデルが GPT-4.1-mini の水準に届けば、h1 の qwen3.8-27b の部分を担う。最も小さいモデルであり h1 の下限を決める。*Criterion:* `qwen3.8-27b.trajectory_smape` $- 0.6007 \leq 0.05$. *Prediction:* $[-0.3, 0]$ (c1 と同じ。最小のモデルのため差が小さい側に出ると見込む). *Observed:* -0.352766. *Verdict:* supported.

Assumed, so that the claims together imply Hypothesis 1:

- temperature 1.0 での 1 回実行の平均 STE (137 件平均) の実行間変動が 0.05 より十分小さいこと。先行する Table 1 再現では件ごとの STE の標準偏差はおよそ 0.27、137 件平均の標準誤差はおよそ 0.02 であった (c1~c6)
- RIKYU の推論 API が提供する各モデルが、公開重みと同等の能力を持つこと。量子化や serving の設定は公開されていない (c1~c6)
- thinking を出力するモデルでも max_tokens 32768 の範囲で本文が返り、本文が空のときの呼び直し (最大 3 回) で十分であること (c1~c6)
- aarch64 向けの libroadrunner 2.7.0 と antimony 2.14.0 が、論文環境の libroadrunner 2.8.0 と同じ軌道と評価値を与えること (c1~c6)
- 平均 STE が GPT-4.1-mini の水準に届くかどうかを代表すること。RMS (modifier あり / なし) と NTS は同じ実行から表として報告するが、判定基準には用いない (c1~c6)
- 論文の GPT-4.1-mini の値 (0.6007) を比較対象とすること。GPT-4.1-mini を同じ Controller で再実行した先行研究でも 0.60 前後であり、論文値をそのまま使う (c1~c6)

Hypothesis 2. 論文が報告する「各ファミリーで pro 版が mini 版を一貫して上回る」という構図は、open-weight の GLM-5.3 系でも成り立ち、glm-5.3 は glm-5.3-flash より SciGym-small の平均 STE が低い。(Duan et al., 2025, s1.p6, s1.p10)

Claim 7 glm-5.3 で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、同条件の glm-5.3-flash の平均 STE 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p6, s1.p10), (h4duan, 2025, s2.p1) *Rationale:* 同一ファミリー・同世代の大小 2 モデルを同じ Controller で比べる直接の検証であり、h2 の全体を担う。*Criterion:* `glm-5.3.trajectory_smape` $- \text{glm-5.3-flash.trajectory_smape} \leq 0$. *Prediction:* $[-0.15, -0.02]$ (論文 Table 1 の pro と mini の STE 差は Gemini で -0.097、GPT で -0.140. open-weight でも同程度か、やや小さい差を予測する). *Observed:* pending. *Verdict:* pending.

Assumed, so that the claims together imply Hypothesis 2:

- glm-5.3-flash が glm-5.3 と同世代の小型版であること。両者の構成は公開されておらず、名前から仮定する (c7)
- 平均 STE の差 1 本で「上回る」を代表すること。論文は STE と RMS の両方で pro > mini としているが、RMS は表で報告するのみで判定には用いない (c7)
- temperature 1.0 での 1 回実行どうしの比較で、差 0 を境とする判定が実行間変動 (標準誤差およそ 0.02) に対して十分頑健であること。差が 0.02 未満のときは結論が揺らぎうる (c7)

判定基準と予測区間の根拠. 仮説 1 の各主張の反証線は「(当該モデルの平均 STE) $-$ (論文の GPT-4.1-mini の STE) ≤ 0.05 」である。GPT-4.1-mini は論文 Table 1 の 6 モデルのうち Claude-3.5-Haiku に次いで STE が大きく、「フロンティアモデルの mini 版に届く」ことの最低線として選んだ。0.05 は、論文 Table 1 で隣り合うモデルの最小差 (Gemini-2.5-Pro の 0.3212 と Claude-3.7-Sonnet の 0.3615 の差 0.04) とほぼ同じで、1 件の STE の標準偏差を 0.27 程度と見積もったときの 137 件平均の標準誤差 (約 0.02) の 2 倍強にあたる。予

測区間は $[-0.30, 0]$ とし、2026 年の open-weight thinking モデルは論文の pro と mini の間に入ると見込む。

仮説 2 の反証線は「glm-5.3 の平均 STE - glm-5.3-flash の平均 STE ≤ 0 」である。論文 Table 1 の pro と mini の STE 差は Gemini で -0.097 、GPT で -0.140 であり、予測区間は $[-0.15, -0.02]$ とする。2 つの 1 回実行の差の標準誤差は約 0.03 なので、差が 0.02 未満のときは結論が揺らぎうることを前提として記録する。

RMS (modifier あり / なし) と NTS も同じ実行から表として報告するが、1 つの主張に置ける判定基準は 1 つであるため、判定には用いない。

4 方法

タスク. 各インスタンスは真の SBML (truth.xml)、反応を取り除いた不完全な SBML (partial.xml)、シミュレーション条件 (truth.sedml) からなる。エージェントは不完全な SBML を受け取り、各ターンで実験 (初期濃度の変更を指定し、真のモデルの時系列を得る)、コード実行 (numpy / pandas / scipy / libsbml と、仮説モデルを走らせる simulate 関数が使える)、提出のいずれかを markdown 形式で返す。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p3)。提出した SBML が無効な場合は追加のデバッグ反復が許され、それでも無効なら不完全 SBML のまま採点される (Duan et al., 2025, s1.p4)。

実行系. ループ、プロンプト、実験の実行はすべて公開コード (h4duan, 2025) の Controller をそのまま用いる。本研究が書くのは、(1) OpenAI 互換 API でモデルを呼ぶ LLM 実装 (公式の GPT 実装と同じく、システムプロンプトと全履歴を毎回送る)、(2) インスタンスごとに 1 プロセスで Controller を起動し、137 件を並列に走らせる駆動部、(3) 各インスタンスの提出モデルと公式データを評価層の入力ファイルに書き出す部分だけである。公式コードでは履歴がクラス属性として定義されており 1 プロセスで複数件を走らせると履歴が持ち越されるが、1 件 1 プロセスとすることでこの問題を避ける。

指標. 採点は評価層 airas-eval のベンチマークパック scigym_small が行う。パックは公式リリースの 137 件 (truth / partial / sedml) を sha256 で固定し、公開コードの Evaluator (コミット 88a7b93) で提出モデルを採点して、STE (trajectory_smape)、RMS の適合率・再現率・F1 (modifier なし reaction_*, あり reaction_*_with_modifiers)、NTS の F1 (topology_f1) を 137 件の単純平均で返す。提出 SBML が無い、または無効な件は、公式評価どおり不完全 SBML の採点値で平均に含める。

5 実験設計

モデル. RIKYU の推論 API が提供する 8 モデルをすべて用いる: deepseek-v4.1-flash、glm-5.2、glm-5.3、glm-5.3-flash、kimi-k2.6、kimi-k3、qwen3.6-35b、qwen3.8-27b。いずれも思考 (thinking) を出力するモデルである。各モデルの量子化や serving の設定は公開されておらず、公開重みと同等の能力を持つことを仮説の前提として記録する。

データ. SciGym-small の 137 件 (Duan et al., 2025, s1.p2) (Hugging Face h4duan/scigym-sbml の small split と同一内容の RIKYU 上のコピー) を用いる。評価層は各件の内容を公式リリースの sha256 と照合する。

設定. max_iterations は論文どおり 20 (Duan et al., 2025, s1.p3) (公開 config の既定値は 5 (h4duan, 2025, s2.p2))、eval_debug_rounds は論文本文の 3 (Duan et al., 2025, s1.p4) (公開 config の既定値は 5 (h4duan, 2025, s2.p3))、temperature は公開 config の 1.0 (h4duan, 2025, s2.p1)、摂動は初期濃度の変更のみとする。応答のトークン上限は 32768 とする。公式の GPT 実装の既定値 8192 では、思考トークンを出すモデルが本文を返せずに失敗しうるためである。本文が空で返った呼び出しは最大 3 回まで呼び直す。各モデル、各インスタンスを 1 回ずつ実行する。

計算資源と環境. 実行は Seyval を通じて RIKYU (Slurm、GB200 ノード、aarch64) で行い、LLM は同じ RIKYU の推論 API を呼ぶ。GPU は使わないが、資源の単位が GPU であるため 1 GPU を要求する。環境は Dockerfile と uv.lock で固定する。aarch64 向けの

Table 1: SciGym-small 137 件における RIKYU の open-weight 5 モデルの平均 STE (低いほど良い)、論文 Table 1 の GPT-4.1-mini (0.6007) との差、Reaction Matching Score の F1 (modifier なし / あり、高いほど良い)、Network Topology Score の F1。glm-5.2、glm-5.3、glm-5.3-flash の 3 run は期限内に終わらず打ち切ったため行がない。

	STE ↓	Δ STE vs GPT-4.1-mini	RMS w/o mod. F1	RMS w/ mod. F1	NTS F1
deepseek-v4.1-flash	0.2405	-0.3602	0.4542	0.2746	0.5698
kimi-k2.6	0.2100	-0.3907	0.4294	0.2651	0.7434
kimi-k3	0.2251	-0.3756	0.4915	0.2924	0.5310
qwen3.6-35b	0.4571	-0.1436	0.2840	0.1465	0.6277
qwen3.8-27b	0.2479	-0.3528	0.4145	0.2517	0.6119

wheel が無いため、libroadrunner は公式の 2.8.0 ではなく 2.7.0、antimony は 2.14.0 を用い、rrplugins と phrasedml は除外する。この差でシミュレーション結果がわずかに変わる可能性があり、仮説の前提として記録する。

段階. sanity は 1 件 (BIOMD0000000027) を 2 反復で走らせて配管を確かめる。pilot は sorted し た 137 件から 14 件おきに選んだ 10 件を 20 反復で走らせ、1 件あたりの所要時間と推論 API の処理能力を測って全件実行の並列度を決める。主張の判定は full (137 件) の結果だけで行い、sanity と pilot の結果は記録に取り込まない。

run と主張の対応. deepseek-v4.1-flash → Claim 1、glm-5.2 → Claim 2、kimi-k2.6 → Claim 3、kimi-k3 → Claim 4、qwen3.6-35b → Claim 5、qwen3.8-27b → Claim 6、glm-5.3 と glm-5.3-flash → Claim 7。

6 結果

表 1 に、完走した 5 モデルの SciGym-small 137 件に対する平均 STE、論文 Table 1 の GPT-4.1-mini (0.6007) (Duan et al., 2025, s1.p5) との差、RMS の F1 (modifier なし / あり)、NTS の F1 を示す。各値は評価層 scigym_small のレポートから記録経由で流し込んだものである。

主張の判定. 仮説 1 の各主張の反証線は「(当該モデルの平均 STE) - 0.6007 ≤ 0.05」である (第 3 節)。平均 STE は kimi-k2.6 が 0.21005、kimi-k3 が 0.225072、deepseek-v4.1-flash が 0.24046、qwen3.8-27b が 0.247934、qwen3.6-35b が 0.457089 であり、Claim 1、3、4、5、6 はいずれも基準を満たした。GPT-4.1-mini との差は -0.39 から -0.14 で、事前に宣言した予測区間 [-0.30, 0] を kimi-k2.6、kimi-k3、deepseek-v4.1-flash、qwen3.8-27b の 4 モデルで下に外れた。すなわち、これらのモデルは予測より大きく GPT-4.1-mini を引き離し、論文 Table 1 で最良だった Gemini-2.5-Pro の 0.3212 (Duan et al., 2025, s1.p5) も下回った。qwen3.6-35b だけが予測区間の内側で、5 モデルの中では最も弱い。

Claim 2 (glm-5.2) と Claim 7 (glm-5.3 と glm-5.3-flash、仮説 2) は、対応する run が期限内に終わらず打ち切ったため結果がなく、判定は保留 (inconclusive) である。経緯は記録の notes に残した。

RMS と NTS. modifier なしの RMS F1 は kimi-k3 0.491461、deepseek-v4.1-flash 0.454218、kimi-k2.6 0.429412、qwen3.8-27b 0.414496、qwen3.6-35b 0.283973 で、論文 Table 1 の GPT-4.1-mini (0.2322) はもちろん、最良の Gemini-2.5-Pro (0.3383) (Duan et al., 2025, s1.p5) も qwen3.6-35b を除く 4 モデルが上回った。modifier ありの厳格版 (Duan et al., 2025, s1.p8) でも同じ 4 モデルが論文最良の 0.1817 を上回る。STE の順位 (kimi-k2.6 < kimi-k3 < deepseek-v4.1-flash < qwen3.8-27b < qwen3.6-35b) と RMS F1 の順位 (kimi-k3 > deepseek-v4.1-flash > kimi-k2.6 > qwen3.8-27b > qwen3.6-35b) は上位で入れ替わり、kimi-k2.6 は軌道は最もよく合うが反応の一致は 3 位である。NTS の F1 は kimi-k2.6 が 0.743372 と突出しており、反応の分割は違っても種間の相互作用の構造はよく捉えている。

完走件数とトークン. 表 2 に各 run の有効提出件数とトークン消費を示す。有効な SBML が提出された件数は kimi-k2.6 の 137 件から qwen3.6-35b と qwen3.8-27b の 129 件までで、

Table 2: 各 run の評価件数、有効な SBML が提出された件数、トークン消費。出力トークンには thinking を含む。入力トークンには本文が空だった応答の呼び直し分を含む。

	n_instances	n_valid_submissions	入力トークン	出力トークン
deepseek-v4.1-flash	137	134	46883266	7105051
kimi-k2.6	137	137	159819464	15120272
kimi-k3	137	130	51346776	4810145
qwen3.6-35b	137	129	82065304	13367361
qwen3.8-27b	137	129	70290128	20989696

残りは提出モデルが無効か、3 回の試行とも LLM のコードが ODE 計算の中で止まって打ち切られた件であり、公式評価どおり不完全モデルの採点値で平均に含めた。入力トークンは kimi-k2.6 が他の 2~3 倍で、これは本文が空の応答（後述）の呼び直し分を含む。

実行で起きたこと. 事前登録した設計からの逸脱と、実行中に判明した事実を記す。第一に、thinking を出力するモデル（特に kimi-k2.6）は、finish_reason が stop なのに本文（content）が空で、思考（reasoning_content）の中にコードブロックまで含む回答が入った応答を返すことがあった。実験コードはこの応答を最初の 1 回で思考の文を本文として Controller に渡した。形式が合わなければ公式の手順どおり Controller がやり直しを求めるので、ベンチマークの規約は変えていない。上限（32768 トークン）で切れた応答は上限を倍にして呼び直した。生の空応答はすべて各件の empty_responses.jsonl として保存してある。第二に、1 件 1 試行の上限は当初 1.5 時間としたが、thinking モデルは 20 反復に 2~4 時間かかり、上限で打ち切られて最初からやり直す件が続出したため、途中で 4 時間（GLM 系は 12 時間）に延ばした。第三に、deepseek-v4.1-flash の最初の run は 136 件が完走し、1 件（BIOMD0000000783）だけが 3 回とも ODE 計算の中で止まって打ち切れ、実験コードが run 全体を失敗と判定して評価に進まなかった。公式の規約では有効な提出がない件は不完全モデルで採点されるので、136 件の出力をそのまま引き継ぎ、打ち切りの 1 件を提出なしとして評価だけを行う run を投げ直した。LLM の呼び出しはやり直していない。第四に、GLM 系の 3 モデルは、RIKYU の推論 API での生成速度（glm-5.3 で約 15 tok/s、glm-5.2 で約 55 tok/s、glm-5.3-flash で約 130 tok/s）と断続的な 502 のため、並列度と試行上限を上げて投げ直しても期限内に終わる見込みが立たず、それぞれ 5 件、13 件、14 件が完走した時点で利用者の判断により打ち切った。途中までの件で集計することはしない。第五に、qwen3.6-35b の推論 API は約 1 日にわたり 1 語の要求にも応答せず、復旧後に実行した。

7 考察

open-weight モデルは論文の商用モデルの水準を超えていた. 仮説 1 は「GPT-4.1-mini の水準に届く」という控えめな線で置いたが、完走した 5 モデルはすべてこれを満たし、4 モデルは論文 Table 1 の最良値をも STE と RMS の両方で上回った。論文の評価は 2025 年前半のモデルによるものであり (Duan et al., 2025, s1.p1)、1 年後の open-weight thinking モデルが同じ閉ループの課題でそれを超えることは、予測区間を下に外れた事実が示すように、本研究の事前の見込みよりも明確であった。ただし比較対象は論文値の転記であり、本研究で商用モデルを再実行してはいない。先行する Table 1 再現では GPT-4.1-mini の平均 STE は論文とほぼ一致し、GPT-4.1 は 0.05 程度、Gemini-2.5-Pro は実行事故を含めて 0.09 程度動いたので、0.1 を超える差は実行の揺らぎでは説明できないと考える。

規模と世代. 5 モデルの中で最も小さい qwen3.8-27b (27B) が kimi-k3 や deepseek-v4.1-flash と 0.02 差に並ぶ一方、より大きい qwen3.6-35b は STE で 0.2 以上劣る。同じ Qwen 系でも世代 (3.6 と 3.8) の差がパラメータ数の差より大きく効いており、この課題で効いているのは規模よりも思考を伴う探索とコード生成の訓練の世代だと読める。仮説 2 (同一ファミリーの大小関係) はこの読みを直接検証するはずだったが、判定できなかった。

thinking モデルを既存のベンチマークで動かすときの落とし穴. 本研究で最も時間を費やしたのは、モデルの能力ではなく serving と実験コードの周辺であった。本文が空で思考に回答が入る応答は、公式実装のように本文だけを読む実装では「空応答」として失敗し、モデルの実力が過小に見える。上限で切れた思考も同じである。また 1 反復に数分かかるモデルでは、1 件の試行に数時間を要し、試行上限と再試行の設計が結果の件数を左右する。これ

らは論文の評価では現れなかった要素で、open-weight モデルの評価を再現可能にするには、応答の取り扱いと打ち切りの規則を事前登録に含めるべきである。本研究では途中で変えた点をすべて記録の notes と本文に残した。

打ち切りの影響. GLM 系 3 モデルの打ち切りにより、仮説 1 の 6 モデルのうち 1 つ (glm-5.2) と仮説 2 の全部が未判定である。これは能力の評価ではなく RIKYU での serving 速度の問題であり、別の serving 環境で実行すれば判定できる。記録は追記のみなので、後日の実行結果は同じ claim に別の結果として追加される。

8 結論

RIKYU の推論 API で提供される open-weight モデルのうち完走した 5 つ (deepseek-v4.1-flash、kimi-k2.6、kimi-k3、qwen3.6-35b、qwen3.8-27b) は、SciGym 公開コードの Controller と評価器をそのまま用いた SciGym-small 137 件の評価で、いずれも論文 Table 1 の GPT-4.1-mini の水準に届き (Claim 1、3、4、5、6 が成立)、うち 4 つは論文の最良値を STE と RMS の両方で上回った。GLM 系 3 モデルは serving の速度の問題で期限内に評価できず、Claim 2 と仮説 2 は保留である。事前登録した予測区間は 4 モデルで下に外れており、open-weight モデルの進歩は本研究の見込みより速かった。

データの利用可能性

記録は record.json にある。実験コード、環境の固定 (Dockerfile と uv.lock)、各 run の結果と provenance は同じリポジトリに含まれる。

REFERENCES

- Haonan Duan, Stephen Zhewen Lu, Caitlin Fiona Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *arXiv preprint arXiv:2507.02083 (NeurIPS 2025 Datasets and Benchmarks Track)*, 2025. URL <https://arxiv.org/pdf/2507.02083>.
- h4duan. h4duan/scigym, 2025. URL <https://github.com/h4duan/SciGym>. commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.